

Master Web Intelligence and Data Science

Module : Statistiques Exploratoires
Multidimensionnelles

Rapport sur la Régression Logistique

Application à l'Analyse de la Qualité du Sommeil

Étude du Dataset : Sleep Health and Lifestyle

Réalisé par :
Farahe EL MONTASER

Encadré par :
Pr. AbdElkamel ALAJ

Année universitaire 2024-2025
Janvier 2025

Table des matières

1	Introduction générale	4
1.1	Contexte et motivation	4
1.1.1	Importance du sommeil dans la qualité de vie	4
1.1.2	Impact sur la santé	4
1.1.3	Influence sur la productivité	5
1.1.4	Pertinence de l'analyse statistique	5
1.2	Problématique	6
1.2.1	Question centrale du projet	6
1.3	Objectifs du projet	7
1.3.1	Objectif général	7
1.3.2	Objectifs spécifiques	7
1.4	Organisation du rapport	7
2	Présentation et exploration des données	9
2.1	Présentation du dataset	9
2.1.1	Source des données	9
2.1.2	Description générale	9
2.1.3	Taille du dataset	9
2.1.4	Nature des variables	10
2.2	Visualisation des données	10
2.2.1	Distributions des variables numériques	10
2.2.2	Détection des valeurs aberrantes	10
2.2.3	Graphiques pour variables catégorielles	11
2.3	Distribution de la variable cible	11
2.4	Matrice de corrélation	11
2.4.1	Analyse des corrélations principales	11
2.4.2	Détection de la multicollinéarité (VIF)	12
2.5	Analyse bivariée	12
2.5.1	Variables numériques vs Variable cible	12
2.5.2	Variables catégorielles vs Variable cible	12
2.6	Synthèse de l'exploration	13
2.6.1	Variables clés identifiées	13
2.6.2	Qualité des données	13
2.6.3	Recommandations pour la modélisation	13
3	Méthodologie statistique	23
3.1	Cadre théorique de la régression logistique	23
3.1.1	Rappel : qu'est-ce que la régression logistique ?	23

3.1.2	Différence avec la régression linéaire	23
3.1.3	Fonction logit et fonction sigmoïde	24
3.2	Formulation mathématique du modèle	24
3.2.1	Modèle de régression logistique binaire	24
3.2.2	Interprétation des paramètres	25
3.3	Hypothèses du modèle logistique	26
3.3.1	Hypothèse 1 : Variable dépendante binaire	26
3.3.2	Hypothèse 2 : Indépendance des observations	26
3.3.3	Hypothèse 3 : Absence de multicollinéarité	26
3.3.4	Hypothèse 4 : Linéarité entre log-odds et variables continues	26
3.3.5	Hypothèse 5 : Taille d'échantillon suffisante	27
3.3.6	Hypothèse 6 : Absence de valeurs extrêmes influentes	27
3.4	Méthode d'estimation : Maximum de vraisemblance	27
3.4.1	Principe général	27
3.4.2	Fonction de vraisemblance	27
3.4.3	Log-vraisemblance	28
3.4.4	Optimisation itérative	28
3.5	Sélection de variables	28
3.5.1	Méthodes de sélection pas à pas (stepwise)	29
3.5.2	Critères de sélection de modèles	29
3.5.3	Test de Wald	30
3.5.4	Stratégie de sélection recommandée	30
3.6	Synthèse méthodologique	31
4	Analyse et résultats sous R	32
4.1	Environnement de travail	32
4.1.1	Logiciel et packages utilisés	32
4.1.2	Chargement et préparation des données	32
4.1.3	Division entraînement/test	33
4.2	Construction du modèle de régression logistique	34
4.2.1	Modèle complet	34
4.2.2	Interprétation des coefficients	34
4.3	Comparaison avec d'autres modèles	34
4.3.1	Méthodologie de comparaison	34
4.3.2	Résultats de la comparaison	35
4.3.3	Matrice de confusion commune	36
4.4	Importance des variables	37
4.4.1	Analyse avec Random Forest	37
4.4.2	Résultats de l'importance	37
4.4.3	Interprétation de l'importance	37
4.4.4	Convergence avec la régression logistique	39
4.5	Validation et diagnostics	39
4.5.1	Courbe ROC	39
4.5.2	Interprétation de la performance exceptionnelle	39
4.6	Synthèse des résultats	40
4.6.1	Variables significatives identifiées	40
4.6.2	Performance des modèles	41
4.6.3	Choix du modèle final	41

4.6.4	Message clé	41
-------	-----------------------	----

Chapitre 1

Introduction générale

1.1 Contexte et motivation

1.1.1 Importance du sommeil dans la qualité de vie

Un sommeil de qualité influence directement notre bien-être quotidien. Il permet la restauration physique et mentale, la consolidation de la mémoire, la régulation émotionnelle et le maintien d'un équilibre psychologique optimal. Les personnes bénéficiant d'un sommeil réparateur rapportent généralement une meilleure qualité de vie, davantage d'énergie au quotidien et une capacité accrue à gérer le stress [11].

Des recherches récentes démontrent qu'une amélioration de la qualité du sommeil conduit à une amélioration significative de la santé mentale, avec des effets mesurables sur la dépression, l'anxiété et le stress [15]. Une étude longitudinale menée en République tchèque a révélé que la qualité du sommeil est le prédicteur le plus robuste de la qualité de vie, davantage que la durée ou le timing du sommeil [3].

À l'inverse, un sommeil perturbé ou insuffisant peut engendrer irritabilité, difficultés de concentration, baisse de motivation et altération des relations sociales et professionnelles.

1.1.2 Impact sur la santé

Les recherches scientifiques ont démontré que la qualité du sommeil est étroitement liée à de nombreux aspects de la santé physique et mentale. Selon l'American Academy of Sleep Medicine, le sommeil est essentiel à la santé et constitue une nécessité biologique [18]. Un sommeil insuffisant ou de mauvaise qualité augmente significativement les risques de développer diverses pathologies :

- **Maladies cardiovasculaires** : Une analyse de plusieurs études a révélé que dormir cinq heures ou moins par nuit peut augmenter le risque de mortalité de 15% [5].
- **Troubles métaboliques** : Les recherches de l'Université de Chicago montrent que la restriction du sommeil entraîne une incapacité de l'insuline à réguler la glycémie et augmente les hormones régulant l'appétit [17]. Les personnes dormant moins de cinq heures par nuit présentent un risque fortement accru de développer un diabète de type 2.
- **Obésité** : Une étude de cohorte sur 13 ans a révélé que les individus dormant moins de six heures à l'âge de 27 ans étaient 7,5 fois plus susceptibles d'avoir un indice de masse corporelle élevé [6].

- **Affections mentales** : Une méta-analyse a démontré qu'améliorer le sommeil conduit à des effets significatifs sur la santé mentale composite, la dépression et l'anxiété [15].
- **Affaiblissement du système immunitaire** : Les personnes dormant moins de sept heures sont trois fois plus susceptibles de développer un rhume que celles dormant huit heures ou plus [5].
- **Troubles cognitifs** : Une étude sur cinq ans a établi qu'une perturbation du sommeil mesurée objectivement est associée à un déclin cognitif plus important chez les adultes âgés [10].

1.1.3 Influence sur la productivité

Dans le contexte professionnel et académique, la qualité du sommeil représente un facteur déterminant de performance. Les études montrent qu'un sommeil réparateur améliore la concentration, la créativité, la prise de décision et la capacité à résoudre des problèmes complexes.

Des recherches récentes ont établi des liens clairs entre le sommeil et la performance au travail :

- **Coûts économiques** : Aux États-Unis, le manque de sommeil des employés génère environ 136 milliards de dollars par an en perte de productivité et 150 milliards en coûts indirects (absentéisme, présentéisme, accidents) [16, 19].
- **Présentéisme** : Une étude japonaise de 2020 a démontré qu'une santé du sommeil insuffisante est associée à une baisse de productivité de 2,99% due au présentéisme [9].
- **Performance cognitive** : 17 heures d'éveil continu entraînent des changements comportementaux équivalents à la consommation de deux verres de vin. Après 24 heures sans sommeil, l'effet équivaut à quatre verres [8].
- **Satisfaction au travail** : Les employés avec une mauvaise qualité de sommeil tendent à être moins satisfaits de leur travail et éprouvent davantage d'émotions négatives [2].
- **Absentéisme** : Une étude longitudinale a révélé qu'une aggravation des troubles du sommeil sur un an est associée à davantage d'absentéisme et à des coûts de santé plus élevés [7].

Plus de 38% des employés américains ont connu de la fatigue au travail au cours des deux dernières semaines, et environ un tiers des Américains dorment régulièrement moins que les sept heures recommandées [14]. Les catastrophes industrielles majeures comme Three Mile Island, Tchernobyl, la marée noire de l'Exxon Valdez et l'explosion de Challenger ont toutes été attribuées à des erreurs humaines causées par la somnolence [8].

1.1.4 Pertinence de l'analyse statistique

Face à l'importance cruciale du sommeil, comprendre les facteurs qui l'influencent devient une nécessité tant pour la santé publique que pour l'amélioration individuelle du bien-être. L'analyse statistique offre des outils puissants pour :

1. **Identifier les déterminants** : quantifier l'impact de différentes variables (mode de vie, caractéristiques personnelles, habitudes) sur la qualité du sommeil.
2. **Établir des relations causales** : distinguer les corrélations simples des véritables facteurs d'influence.

3. **Prédire les risques** : développer des modèles permettant d’anticiper les problèmes de sommeil.
4. **Orienter les interventions** : fournir une base scientifique pour des recommandations personnalisées.

La régression logistique, en particulier, se révèle particulièrement adaptée pour modéliser la qualité du sommeil lorsqu’elle est catégorisée (bon/mauvais sommeil), permettant d’estimer la probabilité d’avoir un sommeil de qualité en fonction de multiples facteurs explicatifs. De nombreuses études ont utilisé avec succès cette approche :

- Une étude sur 20 645 étudiants a développé des modèles prédictifs de la qualité du sommeil basés sur la régression logistique, les réseaux de neurones artificiels et d’autres techniques d’apprentissage automatique [4].
- Des chercheurs ont utilisé la régression logistique pour identifier 11 prédicteurs significatifs de la qualité du sommeil chez les étudiants universitaires, avec une précision de 74% [1].
- Une analyse basée sur la régression logistique a permis de créer un score d’habitudes de sommeil objectif en utilisant des données de capteurs portables [12].
- Des études ont appliqué la régression logistique pour analyser les facteurs influençant le sommeil, incluant l’âge, le stress, l’anxiété et la dépression [13].

1.2 Problématique

Dans un contexte où les troubles du sommeil touchent une proportion croissante de la population mondiale, notamment en raison des modes de vie modernes (stress, sédentarité, exposition aux écrans, rythmes de travail irréguliers), il devient essentiel de comprendre quels facteurs influencent réellement la qualité du sommeil.

1.2.1 Question centrale du projet

Dans quelle mesure les habitudes de sommeil et le mode de vie influencent-ils la qualité du sommeil ?

Cette problématique soulève plusieurs questions secondaires :

- Quels sont les facteurs les plus déterminants pour un sommeil de qualité ?
- L’âge, le sexe et les caractéristiques physiologiques (IMC) jouent-ils un rôle significatif ?
- Comment le niveau de stress et d’activité physique affectent-ils le sommeil ?
- Peut-on quantifier et hiérarchiser l’impact de chaque facteur ?
- Existe-t-il des interactions entre certaines variables explicatives ?

La réponse à cette problématique permettra non seulement de mieux comprendre les mécanismes influençant le sommeil, mais aussi de formuler des recommandations pratiques et personnalisées pour améliorer la qualité du sommeil dans différentes populations.

1.3 Objectifs du projet

1.3.1 Objectif général

Développer un modèle de régression logistique permettant d'identifier et de quantifier les facteurs influençant la qualité du sommeil, afin de mieux comprendre les déterminants d'un sommeil réparateur et de fournir des bases scientifiques pour des interventions ciblées.

1.3.2 Objectifs spécifiques

1. Explorer et caractériser les données

- Analyser la distribution des variables liées au sommeil et au mode de vie
- Identifier les tendances et patterns dans les habitudes de sommeil
- Détecter d'éventuelles anomalies ou valeurs aberrantes

2. Construire un modèle de régression logistique robuste

- Sélectionner les variables explicatives pertinentes
- Estimer les paramètres du modèle par la méthode du maximum de vraisemblance
- Valider les hypothèses sous-jacentes au modèle

3. Identifier les facteurs significatifs

- Déterminer quelles variables ont un impact statistiquement significatif sur la qualité du sommeil
- Quantifier l'ampleur de cet impact à travers les odds ratios
- Hiérarchiser les facteurs selon leur influence

4. Évaluer la performance du modèle

- Mesurer la qualité d'ajustement du modèle aux données
- Estimer la capacité prédictive et la précision du modèle
- Analyser les cas mal classés pour comprendre les limites du modèle

5. Formuler des recommandations pratiques

- Traduire les résultats statistiques en conseils applicables
- Identifier les leviers d'action prioritaires pour améliorer la qualité du sommeil
- Proposer des pistes pour des études ultérieures

1.4 Organisation du rapport

Ce rapport s'articule autour de six chapitres structurés de manière à guider le lecteur de la présentation du problème jusqu'aux conclusions et recommandations.

Chapitre 1 : Introduction générale (présent chapitre) Pose le contexte de l'étude, explicite la problématique et définit les objectifs poursuivis.

Chapitre 2 : Présentation et exploration des données Décrit en détail le dataset utilisé, présente les variables étudiées et propose une analyse descriptive complète avec visualisations graphiques. Ce chapitre permet de se familiariser avec les données et d'identifier les premières tendances.

Chapitre 3 : Méthodologie statistique Expose le cadre théorique de la régression logistique, justifie le choix de cette méthode et détaille la formulation mathématique du modèle ainsi que la méthode d'estimation retenue.

Chapitre 5 : Analyse et résultats sous R Présente l'implémentation pratique du modèle dans le logiciel R, du prétraitement des données à l'estimation des paramètres. Les résultats statistiques sont analysés en détail, incluant les tests de significativité et l'évaluation de la performance du modèle.

Chapitre 5 : Discussion et interprétation Propose une interprétation critique des résultats obtenus, confronte ces résultats aux attentes théoriques et aux connaissances existantes. Les limites méthodologiques et les perspectives d'amélioration sont également discutées.

Chapitre 6 : Conclusion générale Synthétise les principaux résultats, répond à la problématique posée et met en évidence les apports de ce travail pour la compréhension des facteurs influençant la qualité du sommeil.

Le rapport se conclut par les références bibliographiques et des annexes techniques comprenant le code R complet et des visualisations supplémentaires.

Chapitre 2

Présentation et exploration des données

2.1 Présentation du dataset

2.1.1 Source des données

Le jeu de données utilisé pour cette étude provient de la plateforme **Kaggle**. Il s'agit du dataset "*Sleep Health and Lifestyle Dataset*" créé par Laksika Tharmalingam, qui contient des informations sur les habitudes de sommeil et le mode de vie de 374 participants.

- **Source** : Kaggle - Sleep Health and Lifestyle Dataset
- **Auteur** : Laksika Tharmalingam
- **Date de collecte** : 2023
- **Licence** : CC0 : Public Domain (Libre d'utilisation)
- **URL** : <https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dat>

2.1.2 Description générale

Ce dataset a été créé dans le but d'étudier les relations entre les habitudes de sommeil, le mode de vie et la santé globale des individus. Il s'agit de données synthétiques construites à des fins pédagogiques et de recherche.

Contexte de collecte :

- **Population étudiée** : Adultes âgés de 27 à 59 ans
- **Période** : Données collectées en 2023
- **Méthode de collecte** : Données simulées basées sur des questionnaires auto-administrés et des mesures objectives (fréquence cardiaque, nombre de pas quotidiens mesurés par dispositifs connectés)
- **Domaine** : Santé publique et bien-être

2.1.3 Taille du dataset

Le dataset contient :

- **374 observations** (individus/participants)
- **13 variables** (caractéristiques mesurées)

Chaque observation représente un participant unique avec ses caractéristiques démographiques, ses habitudes de sommeil et ses indicateurs de santé et de mode de vie.

2.1.4 Nature des variables

Le dataset est composé de variables de différentes natures permettant une analyse complète. Le tableau ?? résume la répartition par type.

Trouble du sommeil	Effectif	Fréquence (%)
None	219	58.6%
Insomnia	77	20.6%
Sleep Apnea	78	20.9%
Total	374	100%

TABLE 2.1 – Répartition par trouble du sommeil

Analyse des variables catégorielles

L'échantillon présente une répartition équilibrée par sexe (50/50). La majorité (55.9%) présente un excès pondéral. 58.6% ne rapportent aucun trouble du sommeil, tandis que l'insomnie et l'apnée touchent chacune environ 20% des participants.

2.2 Visualisation des données

2.2.1 Distributions des variables numériques




FIGURE 2.1 – Distribution de l'âge - Répartition uniforme entre 27 et 59 ans

2.2.2 Détection des valeurs aberrantes

Observations : Aucune valeur aberrante problématique n'a été détectée.




FIGURE 2.2 – Distribution de la durée du sommeil

2.2.3 Graphiques pour variables catégorielles

2.3 Distribution de la variable cible

Qualité	Effectif	Fréquence (%)
Bad (score < 7)	119	31.8%
Good (score ≥ 7)	255	68.2%
Total	374	100%

TABLE 2.2 – Distribution de la variable cible binaire

Gestion du déséquilibre : La répartition 68/32 révèle un déséquilibre modéré. Nous utiliserons la pondération des classes dans le modèle logistique.

2.4 Matrice de corrélation

2.4.1 Analyse des corrélations principales

Corrélations avec Quality of Sleep

- **Sleep Duration** ($r = 0.88$) : Corrélation très forte et positive
- **Stress Level** ($r = -0.90$) : Corrélation très forte et négative
- **Physical Activity** ($r = 0.32$) : Corrélation modérée et positive
- **Heart Rate** ($r = -0.35$) : Corrélation modérée et négative




FIGURE 2.3 – Distribution de la qualité du sommeil

Variable	VIF	Interprétation
Age	1.15	Aucun problème
Sleep Duration	1.89	Aucun problème
Physical Activity	2.34	Aucun problème
Stress Level	2.67	Aucun problème
Heart Rate	1.92	Aucun problème
Daily Steps	2.01	Aucun problème

TABLE 2.3 – Facteurs d’inflation de la variance (VIF)

2.4.2 Détection de la multicolinéarité (VIF)

Conclusion : Tous les VIF sont inférieurs à 5, indiquant l’absence de multicolinéarité problématique.

2.5 Analyse bivariée

2.5.1 Variables numériques vs Variable cible

Observations :

- **Sleep Duration :** Différence très marquée (7.5h vs 6.3h)
- **Stress Level :** Stress significativement plus élevé pour mauvaise qualité
- **Physical Activity :** Légère différence favorable aux actifs

2.5.2 Variables catégorielles vs Variable cible

Observations :




FIGURE 2.4 – Distribution du niveau de stress

- **BMI** : Les personnes obèses ont 50% de mauvaise qualité vs 20% pour poids normal
- **Sleep Disorder** : Prédicteur très fort

2.6 Synthèse de l'exploration

2.6.1 Variables clés identifiées

1. **Stress Level** - Impact négatif majeur
2. **Sleep Duration** - Impact positif majeur
3. **Sleep Disorder** - Différenciation très nette
4. **BMI Category** - Impact modéré

2.6.2 Qualité des données

- Aucune valeur manquante
- Aucune valeur aberrante problématique
- Absence de multicollinéarité sévère
- Variables bien distribuées

2.6.3 Recommandations pour la modélisation

1. Transformer Blood Pressure en deux variables numériques
2. Appliquer une pondération des classes
3. Inclure toutes les variables
4. Considérer des interactions potentielles




FIGURE 2.5 – Distribution de l'activité physique

5. Utiliser une validation croisée

Les données sont de bonne qualité et prêtes pour la régression logistique.




FIGURE 2.6 – Distribution du nombre de pas quotidiens




FIGURE 2.7 – Distribution de la fréquence cardiaque




FIGURE 2.8 – Boxplots pour la détection de valeurs aberrantes




FIGURE 2.9 – Répartition par sexe




FIGURE 2.10 – Répartition par catégorie IMC




FIGURE 2.11 – Répartition par trouble du sommeil




FIGURE 2.12 – Distribution de la variable cible binarisée

Matrice de Corrélation des Variables Numériques




FIGURE 2.13 – Matrice de corrélation des variables numériques




FIGURE 2.14 – Boxplots comparatifs selon la qualité du sommeil




FIGURE 2.15 – Qualité du sommeil par catégorie IMC




FIGURE 2.16 – Qualité du sommeil par trouble

Bibliographie

- [1] Alsaggaf, M., Wali, S., Merdad, R., and Merdad, L. (2020). Predictors of sleep quality among university students. *Sleep and Breathing*, 24(3) :1151–1165.
- [2] Barnes, C., Lucianetti, L., Bhave, D., and Christian, M. (2013). You wouldn’t like me when i’m sleepy. *Academy of Management Journal*, 56(5) :1–22.
- [3] Bušková, J., Piešová, M., and Murgaš, F. (2023). Better sleep, better life? *PLOS ONE*, 18(3) :e0282085.
- [4] Chen, Z., Lin, L., Chen, L., et al. (2023). Prediction models for sleep quality among college students. *JMIR*, 25(1) :e45721.
- [5] Harvard Medical School (2024). Sleep and health. Division of Sleep Medicine.
- [6] Hasler, G., Buysse, D., Klaghofer, R., et al. (2004). The association between short sleep duration and obesity. *Sleep*, 27(4) :661–666.
- [7] Hui, S. and Grandner, M. (2015). Trouble sleeping associated with lower work performance. *JOEM*, 57(10) :1031–1038.
- [8] Hult International Business School (2021). How sleep deprivation affects work and performance.
- [9] Komada, Y., Narisawa, H., Ueda, F., et al. (2020). Association between work productivity and sleep health. *Sleep Medicine : X*, 2 :100018.
- [10] Lauderdale, D. et al. (2019). Objectively measured sleep and cognition. *Sleep*, 42(5).
- [11] Lee, S., Wuertz, C., Rogers, R., and Chen, Y. (2021). Stress and sleep disturbances. *AJHB*, 37(6) :851–858.
- [12] Lee, M., Kim, J., Park, S., et al. (2023). A study on ML-based sleep score model. *Applied Sciences*, 13(2) :1043.
- [13] Lin, C., Huang, Y., Zhang, X., et al. (2022). Linear regression analysis of sleep quality. *CMMM*, 2022 :1–8.
- [14] National Sleep Foundation (2025). Sleep in America poll.
- [15] Scott, A., Webb, T., Martyn-St James, M., et al. (2021). Improving sleep quality leads to better mental health. *Sleep Medicine Reviews*, 60 :101556.
- [16] Shortlister (2023). The link between work productivity and sleep.
- [17] Tasali, E., Chapotot, F., Wroblewski, K., and Schoeller, D. (2015). The effects of extended bedtimes. *Appetite*, 80 :220–224.
- [18] Watson, N. et al. (2015). Sleep is essential to health. *JCSM*, 11(6) :591–592.
- [19] World Economic Forum (2019). Workplace wellness report.

Chapitre 3

Méthodologie statistique

3.1 Cadre théorique de la régression logistique

3.1.1 Rappel : qu'est-ce que la régression logistique ?

La régression logistique est une méthode statistique utilisée pour modéliser la relation entre une variable dépendante binaire (prenant deux valeurs : 0 ou 1, succès ou échec, présence ou absence) et une ou plusieurs variables explicatives, qui peuvent être quantitatives ou qualitatives.

Contrairement à la régression linéaire simple qui prédit directement une valeur numérique continue, la régression logistique prédit la **probabilité** qu'un événement se produise. Dans notre contexte, il s'agit de prédire la probabilité qu'un individu ait une **bonne qualité de sommeil** en fonction de ses habitudes de vie.

3.1.2 Différence avec la régression linéaire

Le tableau 3.1 présente les principales différences entre régression linéaire et régression logistique.

Caractéristique	Régression linéaire	Régression logistique
Variable dépendante	Continue (quantitative)	Binaire (qualitative)
Valeurs prédites	$-\infty$ à $+\infty$	Probabilité entre 0 et 1
Fonction de lien	Identité ($y = x$)	Logit (sigmoïde)
Méthode d'estimation	Moindres carrés ordinaires	Maximum de vraisemblance
Distribution des erreurs	Normale	Binomiale
Relation avec X	Linéaire	Linéaire avec le log-odds
Interprétation des coefficients	Changement dans Y pour une unité de X	Changement dans le log-odds

TABLE 3.1 – Comparaison entre régression linéaire et régression logistique

Pourquoi ne pas utiliser la régression linéaire pour une variable binaire ?

- Les prédictions peuvent sortir de l'intervalle $[0, 1]$
- Les résidus ne suivent pas une distribution normale
- La variance n'est pas homogène (hétéroscédasticité)
- La relation n'est pas linéaire mais sigmoïdale

3.1.3 Fonction logit et fonction sigmoïde

La fonction logit

La fonction **logit** (ou log-odds) transforme une probabilité $p \in [0, 1]$ en une valeur réelle dans $] -\infty, +\infty[$:

$$\text{logit}(p) = \ln \left(\frac{p}{1-p} \right) \quad (3.1)$$

où :

- p est la probabilité de succès
- $\frac{p}{1-p}$ est l'**odds** (cote) ou rapport de chance
- $\ln$ est le logarithme naturel

Interprétation de l'odds :

- Si $p = 0.8$: odds = $\frac{0.8}{0.2} = 4$ (4 fois plus de chances de succès que d'échec)
- Si $p = 0.5$: odds = $\frac{0.5}{0.5} = 1$ (chances égales)
- Si $p = 0.2$: odds = $\frac{0.2}{0.8} = 0.25$ (4 fois moins de chances de succès)

La fonction sigmoïde (logistique inverse)

La fonction **sigmoïde** est la fonction inverse du logit. Elle transforme une valeur réelle en probabilité :

$$p = \sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z} \quad (3.2)$$

Cette fonction a une forme en "S" caractéristique (figure 3.1.3).

Propriétés de la fonction sigmoïde :

- $\lim_{z \rightarrow -\infty} \sigma(z) = 0$
- $\lim_{z \rightarrow +\infty} \sigma(z) = 1$
- $\sigma(0) = 0.5$
- Fonction monotone croissante
- Symétrique par rapport au point (0, 0.5)




figure Courbe de la fonction Sigmoïde

3.2 Formulation mathématique du modèle

3.2.1 Modèle de régression logistique binaire

Soit Y notre variable dépendante binaire :

- $Y = 1$: Bonne qualité de sommeil (Quality of Sleep ≥ 7)
- $Y = 0$: Mauvaise qualité de sommeil (Quality of Sleep < 7)

Soit $X_1, X_2, \dots, X_p$ les p variables explicatives (âge, durée du sommeil, stress, etc.).

Forme du modèle avec le logit

Le modèle de régression logistique s'écrit :

$$\text{logit}(P(Y = 1|X)) = \ln \left(\frac{P(Y = 1|X)}{1 - P(Y = 1|X)} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p \quad (3.3)$$

ou de manière plus compacte :

$$\text{logit}(P(Y = 1|X)) = \beta_0 + \sum_{j=1}^p \beta_j X_j \quad (3.4)$$

Forme du modèle avec la probabilité

En inversant la transformation logit, on obtient la probabilité de succès :

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}} \quad (3.5)$$

ou encore :

$$P(Y = 1|X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}} \quad (3.6)$$

3.2.2 Interprétation des paramètres

L'ordonnée à l'origine β_0

β_0 représente le log-odds (logit) lorsque toutes les variables explicatives sont nulles. Dans la pratique, cette valeur seule a rarement une interprétation directe significative.

Les coefficients de régression β_j

Chaque coefficient β_j mesure l'effet d'une augmentation d'une unité de X_j sur le **log-odds** de succès, toutes les autres variables étant maintenues constantes.

Interprétation directe :

- Si $\beta_j > 0$: X_j augmente la probabilité de succès (effet positif)
- Si $\beta_j < 0$: X_j diminue la probabilité de succès (effet négatif).
- Si $\beta_j = 0$: X_j n'a pas d'effet sur la probabilité

Les odds ratios (rapports de cotes)

L'exponentielle du coefficient, e^{β_j} , s'appelle l'**odds ratio** (OR). Elle mesure le facteur multiplicatif de l'odds lorsque X_j augmente d'une unité :

$$OR_j = e^{\beta_j} \quad (3.7)$$

Interprétation pratique :

- Si $OR = 2$: augmenter X_j d'une unité **double** l'odds de succès
- Si $OR = 0.5$: augmenter X_j d'une unité **réduit de moitié** l'odds
- Si $OR = 1$: X_j n'a pas d'effet

Exemple concret :

Supposons que pour la variable "Stress Level", on obtienne $\beta_{stress} = -0.693$.

L'odds ratio est : $OR = e^{-0.693} = 0.5$

Interprétation : Une augmentation d'un point sur l'échelle de stress réduit de 50% l'odds d'avoir une bonne qualité de sommeil, toutes choses égales par ailleurs.

3.3 Hypothèses du modèle logistique

Contrairement à la régression linéaire, la régression logistique repose sur des hypothèses moins restrictives, mais certaines conditions doivent néanmoins être respectées.

3.3.1 Hypothèse 1 : Variable dépendante binaire

La variable à expliquer doit être **binaire** ou dichotomique, c'est-à-dire prendre exactement deux valeurs (codées 0 et 1).

Dans notre étude : Quality_Binary avec modalités "Bad" (0) et "Good" (1).

3.3.2 Hypothèse 2 : Indépendance des observations

Les observations doivent être **indépendantes** les unes des autres. Il ne doit pas y avoir de mesures répétées sur les mêmes individus ni de structure hiérarchique non prise en compte.

Dans notre étude : Chaque ligne représente un individu unique. Les 374 participants sont différents et leurs mesures sont indépendantes.

3.3.3 Hypothèse 3 : Absence de multicolinéarité

Les variables explicatives ne doivent pas être trop fortement corrélées entre elles. Une multicolinéarité excessive rend les estimations instables et les intervalles de confiance très larges.

Détection :

- Matrice de corrélation
- **VIF (Variance Inflation Factor) :**
 - $VIF > 10$: indique un problème sévère de multicolinéarité.
 - $VIF > 5$: indique une corrélation modérée nécessitant une attention.

Dans notre étude : Le VIF a été calculé (Chapitre 2). Toutes les valeurs sont < 3 , donc aucun problème de multicolinéarité.

3.3.4 Hypothèse 4 : Linéarité entre log-odds et variables continues

Pour chaque variable continue X_j , la relation entre X_j et le **logit** de la probabilité doit être linéaire. Cela ne signifie pas que la relation avec la probabilité elle-même est linéaire (elle est sigmoïdale), mais que :

$$\text{logit}(P(Y = 1)) = \beta_0 + \beta_j X_j + \dots \quad (3.8)$$

est une relation linéaire en X_j .

Vérification :

- Méthode du Box-Tidwell : tester l'interaction entre X_j et $\ln(X_j)$
- Analyse graphique des résidus
- Si non-linéarité détectée : transformer la variable (log, polynôme, splines)

3.3.5 Hypothèse 5 : Taille d'échantillon suffisante

La régression logistique nécessite un échantillon de taille adéquate pour des estimations fiables.

Règle générale :

- Au minimum **10 à 15 événements par variable explicative** dans la catégorie la moins fréquente
- Pour p variables explicatives et un événement rare, il faut au moins $10p$ à $15p$ observations de la classe minoritaire

Dans notre étude :

- Classe minoritaire : "Bad" = 119 observations
- Nombre de variables : environ 8-10 variables explicatives
- Ratio : $119/10 \approx 12$ événements par variable
- **Conclusion :** Taille d'échantillon acceptable

3.3.6 Hypothèse 6 : Absence de valeurs extrêmes influentes

Les valeurs aberrantes peuvent fortement influencer les estimations.

Détection :

- Distance de Cook
- DFBeta
- Analyse des résidus de déviance

3.4 Méthode d'estimation : Maximum de vraisemblance

3.4.1 Principe général

Contrairement à la régression linéaire qui utilise les moindres carrés ordinaires, la régression logistique estime les paramètres β par la méthode du **maximum de vraisemblance** (MLE : Maximum Likelihood Estimation).

Idée intuitive : On cherche les valeurs de $\beta_0, \beta_1, \dots, \beta_p$ qui maximisent la probabilité d'observer les données que nous avons effectivement observées.

3.4.2 Fonction de vraisemblance

Pour un échantillon de n observations indépendantes (y_i, x_i) , où $y_i \in \{0, 1\}$, la fonction de vraisemblance s'écrit :

$$L(\beta) = \prod_{i=1}^n P(Y = y_i | X = x_i) \quad (3.9)$$

Avec :

$$P(Y = y_i | X = x_i) = p_i^{y_i} (1 - p_i)^{1-y_i} \quad (3.10)$$

$$\text{où } p_i = P(Y = 1|X = x_i) = \frac{e^{\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}}}{1 + e^{\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}}}$$

3.4.3 Log-vraisemblance

En pratique, on maximise la **log-vraisemblance** $\ell(\beta) = \ln(L(\beta))$:

$$\ell(\beta) = \sum_{i=1}^n [y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)] \quad (3.11)$$

ou encore :

$$\ell(\beta) = \sum_{i=1}^n \left[y_i (\beta_0 + \beta^T x_i) - \ln(1 + e^{\beta_0 + \beta^T x_i}) \right] \quad (3.12)$$

3.4.4 Optimisation itérative

Il n'existe **pas de solution analytique fermée** pour maximiser $\ell(\beta)$. L'estimation se fait donc par des **algorithmes itératifs** :

Algorithme de Newton-Raphson

C'est la méthode la plus couramment utilisée. Elle utilise les dérivées première et seconde de la log-vraisemblance :

$$\beta^{(t+1)} = \beta^{(t)} + H^{-1}(\beta^{(t)}) \nabla \ell(\beta^{(t)}) \quad (3.13)$$

où :

- $\nabla \ell(\beta)$ est le gradient (vecteur des dérivées partielles)
- $H(\beta)$ est la matrice hessienne (matrice des dérivées secondes)

Algorithme IRLS (Iteratively Reweighted Least Squares)

Équivalent à Newton-Raphson pour la régression logistique. À chaque itération, on résout un problème de moindres carrés pondérés.

Convergence

L'algorithme s'arrête lorsque :

- La variation des paramètres devient négligeable : $|\beta^{(t+1)} - \beta^{(t)}| \leq \epsilon$
- La variation de la log-vraisemblance devient négligeable
- Un nombre maximal d'itérations est atteint

Note pratique : Les logiciels statistiques (R, Python, SAS) gèrent automatiquement cette optimisation. L'utilisateur doit simplement vérifier que l'algorithme a convergé correctement.

3.5 Sélection de variables

La sélection de variables consiste à choisir le sous-ensemble optimal de variables explicatives pour construire un modèle à la fois parcimonieux et performant.

3.5.1 Méthodes de sélection pas à pas (stepwise)

Sélection ascendante (Forward selection)

Principe :

1. Partir du modèle vide (sans variables)
2. À chaque étape, ajouter la variable qui améliore le plus le modèle
3. S'arrêter quand aucune variable n'améliore significativement le modèle

Critère d'ajout : p-value < seuil (souvent 0.05 ou 0.10)

Sélection descendante (Backward elimination)

Principe :

1. Partir du modèle complet (toutes les variables)
2. À chaque étape, retirer la variable la moins significative
3. S'arrêter quand toutes les variables restantes sont significatives

Critère de retrait : p-value $\geq$ seuil (souvent 0.10 ou 0.15)

Sélection bidirectionnelle (Stepwise both)

Combinaison des deux approches : à chaque étape, on peut ajouter ou retirer une variable.

Avantages et inconvénients :

Méthode	Avantages	Inconvénients
Forward	Rapide, facile à interpréter	Peut manquer des interactions
Backward	Considère toutes les variables au départ	Plus coûteux en calcul
Stepwise	Équilibre entre les deux	Peut être instable

TABLE 3.2 – Comparaison des méthodes de sélection

3.5.2 Critères de sélection de modèles

Test du rapport de vraisemblance (Likelihood Ratio Test)

Compare deux modèles emboîtés (l'un est un sous-ensemble de l'autre) :

$$LRT = -2(\ell_{réduit} - \ell_{complet}) = -2 \ln \left(\frac{L_{réduit}}{L_{complet}} \right) \quad (3.14)$$

Sous H_0 (le modèle réduit est suffisant), $LRT \sim \chi_k^2$ où k est la différence du nombre de paramètres.

Décision : Si $LRT > \chi_{k,\alpha}^2$, on rejette H_0 et on garde le modèle complet.

Critère d'information d'Akaike (AIC)

$$AIC = -2\ell(\hat{\beta}) + 2p \quad (3.15)$$

où p est le nombre de paramètres du modèle.

Principe : Choisir le modèle avec le **plus petit AIC**. L'AIC pénalise la complexité du modèle.

Critère d'information bayésien (BIC)

$$BIC = -2\ell(\hat{\beta}) + p \ln(n) \quad (3.16)$$

où n est la taille de l'échantillon.

Principe : Choisir le modèle avec le **plus petit BIC**. Le BIC pénalise plus fortement la complexité que l'AIC.

Comparaison AIC vs BIC

- **AIC :** Favorise des modèles légèrement plus complexes, meilleur pour la prédiction
- **BIC :** Favorise des modèles plus parcimonieux, meilleur pour l'explication
- Pour $n > 8$, BIC pénalise plus que AIC

3.5.3 Test de Wald

Le test de Wald évalue la significativité d'un coefficient individuel β_j :

$$W_j = \left(\frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \right)^2 \sim \chi_1^2 \quad (3.17)$$

où $SE(\hat{\beta}_j)$ est l'erreur standard de $\hat{\beta}_j$.

Équivalent : La statistique $z = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$ suit approximativement une loi $\mathcal{N}(0, 1)$.

3.5.4 Stratégie de sélection recommandée

Pour notre étude sur la qualité du sommeil :

1. **Analyse univariée :** Tester chaque variable indépendamment
2. **Sélection initiale :** Retenir les variables avec $p < 0.20$ -0.25
3. **Modèle complet :** Inclure toutes les variables retenues
4. **Sélection stepwise :** Appliquer une sélection bidirectionnelle avec p -entrée = 0.05 et p -sortie = 0.10
5. **Vérification des interactions :** Tester les interactions plausibles
6. **Validation :** Comparer AIC/BIC et valider sur un échantillon test

3.6 Synthèse méthodologique

Ce chapitre a présenté les fondements théoriques de la régression logistique :

- La transformation logit permet de modéliser une probabilité
- Le modèle relie linéairement le log-odds aux variables explicatives
- Les paramètres sont estimés par maximum de vraisemblance
- Les odds ratios facilitent l'interprétation
- La sélection de variables repose sur des critères statistiques rigoureux

Le chapitre suivant présentera l'application pratique de cette méthodologie sur notre dataset Sleep Health à l'aide du logiciel R.

Chapitre 4

Analyse et résultats sous R

4.1 Environnement de travail

4.1.1 Logiciel et packages utilisés

L'ensemble des analyses a été réalisé avec le logiciel R version 4.5.2 dans l'environnement RStudio. Les packages suivants ont été utilisés :

Package	Version	Utilisation
tidyverse	2.0.0	Manipulation et visualisation des données
caret	6.0-94	Prétraitement et validation croisée
car	3.1-2	Calcul des VIF et diagnostics
pROC	1.18.5	Courbes ROC et calcul de l'AUC
ggplot2	3.5.0	Visualisations avancées
corrplot	0.92	Matrices de corrélation
randomForest	4.7-1.1	Modèle Random Forest
e1071	1.7-14	Support Vector Machine
MASS	7.3-60	Sélection de variables (stepwise)

TABLE 4.1 – Packages R utilisés pour l'analyse

4.1.2 Chargement et préparation des données

Importation des données

Le code suivant permet d'importer et d'explorer les données :

```
# Chargement des packages
library(tidyverse)
library(caret)
library(car)
library(pROC)
library(randomForest)
library(e1071)

# Importation du dataset
```

```
sleep_data <- read.csv("Sleep_health_and_lifestyle_dataset.csv",
                      stringsAsFactors = TRUE)
```

```
# Aperçu des données
str(sleep_data)
summary(sleep_data)
```

Prétraitement des données

Création de la variable cible binaire La variable `Quality.of.Sleep` a été transformée en variable binaire selon le seuil de 7 :

```
# Création de Quality_Binary
sleep_data <- sleep_data %>%
  mutate(Quality_Binary = ifelse(Quality.of.Sleep >= 7, "Good", "Bad"),
         Quality_Binary = factor(Quality_Binary,
                                levels = c("Bad", "Good")))

# Vérification de la distribution
table(sleep_data$Quality_Binary)
prop.table(table(sleep_data$Quality_Binary))
```

Résultat :

- Bad : 119 observations (31.8%)
- Good : 255 observations (68.2%)

4.1.3 Division entraînement/test

Pour évaluer la performance du modèle, les données ont été divisées en deux ensembles avec stratification :

```
# Fixation de la graine pour reproductibilité
set.seed(123)

# Division stratifiée 80/20
trainIndex <- createDataPartition(sleep_data$Quality_Binary,
                                  p = 0.8,
                                  list = FALSE)

# Création des ensembles
train_data <- sleep_data[trainIndex, ]
test_data <- sleep_data[-trainIndex, ]

# Normalisation pour SVM
preproc <- preProcess(train_data[, sapply(train_data, is.numeric)],
                      method = c("center", "scale"))
train_scaled <- predict(preproc, train_data)
test_scaled <- predict(preproc, test_data)
```

Résultat :

- Entraînement : 299 observations (80%)
- Test : 74 observations (20%)
- Proportions préservées dans les deux ensembles

4.2 Construction du modèle de régression logistique

4.2.1 Modèle complet

Le modèle de régression logistique a été estimé en incluant toutes les variables pertinentes :

```
# Estimation du modèle de régression logistique
model_log <- glm(Quality_Binary ~ .,
                 data = train_data,
                 family = binomial(link = "logit"))

# Résumé du modèle
summary(model_log)
```

Note : Le message d’avertissement ”glm.fit : des probabilités ont été ajustées numériquement à 0 ou 1” indique une séparation quasi-parfaite des classes, ce qui est cohérent avec la nature synthétique des données et la forte capacité discriminante des prédicteurs.

4.2.2 Interprétation des coefficients

Le modèle identifie plusieurs prédicteurs significatifs :

- **Stress.Level** : Coefficient négatif fort (effet délétère majeur)
- **Sleep.Duration** : Coefficient positif fort (effet bénéfique majeur)
- **Heart.Rate** : Coefficient négatif modéré (marqueur physiologique)
- **Physical.Activity.Level** : Coefficient positif modéré (effet bénéfique)
- **Sleep.Disorder** : Coefficients négatifs forts pour Insomnia et Sleep Apnea

4.3 Comparaison avec d’autres modèles

Pour évaluer la performance relative de la régression logistique, trois algorithmes ont été comparés sur les mêmes données.

4.3.1 Méthodologie de comparaison

Algorithmes testés

1. **Régression Logistique** : Modèle linéaire généralisé avec lien logit
2. **Random Forest** : Ensemble de 500 arbres de décision
3. **SVM RBF** : Machine à vecteurs de support avec noyau radial

Code de comparaison

```
# --- Régression Logistique ---
start_log <- Sys.time()
model_log <- glm(Quality_Binary ~ .,
                 data = train_data,
                 family = binomial(link = "logit"))
prob_log <- predict(model_log, test_data, type = "response")
pred_log <- factor(ifelse(prob_log >= 0.5, "Good", "Bad"),
                  levels = c("Bad", "Good"))
time_log <- as.numeric(difftime(Sys.time(), start_log,
                               units = "secs")) * 1000

# --- Random Forest ---
start_rf <- Sys.time()
model_rf <- randomForest(Quality_Binary ~ .,
                         data = train_data,
                         ntree = 500,
                         importance = TRUE)
prob_rf <- predict(model_rf, test_data, type = "prob")[,2]
pred_rf <- predict(model_rf, test_data)
time_rf <- as.numeric(difftime(Sys.time(), start_rf,
                               units = "secs")) * 1000

# --- SVM RBF ---
start_svm <- Sys.time()
model_svm <- svm(Quality_Binary ~ .,
                 data = train_scaled,
                 kernel = "radial",
                 probability = TRUE)
svm_res <- predict(model_svm, test_scaled, probability = TRUE)
prob_svm <- attr(svm_res, "probabilities")[,"Good"]
pred_svm <- predict(model_svm, test_scaled)
time_svm <- as.numeric(difftime(Sys.time(), start_svm,
                               units = "secs")) * 1000
```

4.3.2 Résultats de la comparaison

Tableau comparatif des performances

```
# Calcul des performances
results <- data.frame(
  Modele = c("Régression Logistique", "Random Forest", "SVM RBF"),
  Accuracy = c(
    confusionMatrix(pred_log, test_data$Quality_Binary)$overall['Accuracy'],
    confusionMatrix(pred_rf, test_data$Quality_Binary)$overall['Accuracy'],
    confusionMatrix(pred_svm, test_data$Quality_Binary)$overall['Accuracy']
  ),
  AUC = c(
```

```

    auc(roc(test_data$Quality_Binary, prob_log, quiet=TRUE)),
    auc(roc(test_data$Quality_Binary, prob_rf, quiet=TRUE)),
    auc(roc(test_data$Quality_Binary, prob_svm, quiet=TRUE))
  ),
  Temps_ms = c(time_log, time_rf, time_svm)
)

print(results)

```

Modèle	Accuracy	AUC	Temps (ms)
Régression Logistique	0.9865 (98.65%)	1.0000	21.11
Random Forest	0.9865 (98.65%)	1.0000	101.35
SVM RBF	0.9865 (98.65%)	1.0000	20.26

TABLE 4.2 – Comparaison des performances des modèles sur l’ensemble de test (n=74)

Analyse des résultats

Observations remarquables :

- **Performance identique** : Les trois modèles atteignent exactement la même accuracy (98.65%) et AUC (1.0000)
- **Une seule erreur** : Sur 74 prédictions, un seul cas a été mal classé par chaque modèle
- **Efficacité computationnelle** :
 - SVM RBF : le plus rapide (20.26 ms)
 - Régression Logistique : très rapide (21.11 ms)
 - Random Forest : 5× plus lent (101.35 ms)
- **Séparation parfaite** : L’AUC de 1.0000 indique une discrimination parfaite entre les deux classes

Explication de la performance exceptionnelle :

1. **Variables hautement discriminantes** : Stress Level et Sleep Duration créent une séparation quasi-linéaire entre les classes
2. **Nature synthétique** : Les données simulées présentent des patterns très réguliers
3. **Taille d’échantillon** : 74 observations de test facilitent la classification parfaite

4.3.3 Matrice de confusion commune

```

# Matrice de confusion (identique pour les trois modèles)
confusionMatrix(pred_log, test_data$Quality_Binary)

```

Matrice de confusion (tous modèles)		
	Prédit Bad	Prédit Good
Réel Bad	22	1
Réel Good	0	51

TABLE 4.3 – Matrice de confusion commune aux trois modèles

Métriques détaillées :

- **Vrais positifs (TP)** : 51 (bonne qualité correctement identifiée)
- **Vrais négatifs (TN)** : 22 (mauvaise qualité correctement identifiée)
- **Faux positifs (FP)** : 1 (mauvaise qualité prédite comme bonne)
- **Faux négatifs (FN)** : 0 (aucune bonne qualité manquée)

Calcul des métriques :

- $\text{Accuracy} = \frac{TP+TN}{Total} = \frac{51+22}{74} = 0.9865$
- $\text{Sensibilité (Recall)} = \frac{TP}{TP+FN} = \frac{51}{51+0} = 1.0000$
- $\text{Spécificité} = \frac{TN}{TN+FP} = \frac{22}{22+1} = 0.9565$
- $\text{Précision} = \frac{TP}{TP+FP} = \frac{51}{51+0} = 1.0000$

4.4 Importance des variables

4.4.1 Analyse avec Random Forest

L'importance des variables a été calculée à partir du modèle Random Forest :

```
# Extraction de l'importance des variables
imp <- as.data.frame(importance(model_rf))
print(imp[order(-imp$MeanDecreaseGini), ])
```

4.4.2 Résultats de l'importance

Rang	Variable	Bad	Good	MDA	MDG
1	Stress.Level	26.03	24.54	29.89	50.67
2	Sleep.Duration	26.95	22.60	31.18	38.54
3	Heart.Rate	15.12	11.99	16.89	21.42
4	Age	20.74	14.40	22.75	6.09
5	Daily.Steps	8.54	8.33	9.91	4.77
6	Physical.Activity.Level	6.79	6.95	8.00	2.57
7	Gender	10.37	7.66	11.54	1.78
8	Sleep.Disorder	3.85	7.72	7.81	1.38
9	BMI.Category	2.54	5.76	5.35	1.11

TABLE 4.4 – Importance des variables selon Random Forest.
MDA = MeanDecreaseAccuracy, MDG = MeanDecreaseGini

4.4.3 Interprétation de l'importance

Hiérarchie des facteurs

Le score **MeanDecreaseGini** (MDG) mesure l'importance de chaque variable pour la pureté des partitions dans les arbres de décision. Plus le score est élevé, plus la variable est importante.

Facteurs dominants (MDG $\geq$ 20)

1. **Stress.Level (50.67)** : Facteur le plus important, expliquant à lui seul 39.8% de l'importance totale

- Contribution équilibrée aux deux classes (Bad : 26.03, Good : 24.54)
- Impact majeur sur l'accuracy (MDA = 29.89)
- 2. **Sleep.Duration (38.54)** : Deuxième facteur majeur (30.3% de l'importance)
 - Contribution légèrement plus forte pour la classe Bad (26.95 vs 22.60)
 - Plus forte contribution à l'accuracy (MDA = 31.18)
- 3. **Heart.Rate (21.42)** : Troisième facteur significatif (16.8% de l'importance)
 - Contribution modérée mais constante
 - Marqueur physiologique important de la qualité du sommeil

Les trois premiers facteurs représentent 86.9% de l'importance totale, confirmant leur rôle prépondérant.

Facteurs secondaires (5 ; MDG ; 10)

- **Age (6.09)** : Effet modéré, probablement non-linéaire
- **Daily.Steps (4.77)** : Impact mesurable de l'activité objective

Facteurs tertiaires (MDG ; 5)

- **Physical.Activity.Level (2.57)** : Effet positif mais faible
- **Gender (1.78)** : Contribution négligeable
- **Sleep.Disorder (1.38)** : Effet capturé par d'autres variables
- **BMI.Category (1.11)** : Impact minimal direct

Graphique d'importance




FIGURE 4.1 – Importance des variables selon le critère MeanDecreaseGini

4.4.4 Convergence avec la régression logistique

Les résultats du Random Forest **confirment parfaitement** la hiérarchie identifiée par la régression logistique :

Variable	RF (MDG)	RL (p-value)
Stress.Level	50.67 (rang 1)	0.0001***
Sleep.Duration	38.54 (rang 2)	0.0002***
Heart.Rate	21.42 (rang 3)	0.0040**
Physical.Activity.Level	2.57 (rang 6)	0.0237*
Sleep.Disorder	1.38 (rang 8)	0.0031** (Insomnia)

TABLE 4.5 – Convergence entre Random Forest et Régression Logistique

Cette convergence entre deux approches méthodologiquement très différentes renforce considérablement la robustesse de nos conclusions.

4.5 Validation et diagnostics

4.5.1 Courbe ROC

```
# Calcul de la courbe ROC pour la régression logistique
roc_log <- roc(test_data$Quality_Binary, prob_log, quiet = TRUE)
auc_log <- auc(roc_log)

# Graphique
plot(roc_log,
     main = "Courbe ROC - Régression Logistique",
     col = "blue",
     lwd = 2)
text(0.5, 0.3, paste("AUC =", round(auc_log, 4)), cex = 1.2)
```

Interprétation :

- **AUC = 1.0000** : Discrimination parfaite entre les deux classes
- La courbe suit parfaitement les axes (coin supérieur gauche)
- Aucun compromis sensibilité-spécificité nécessaire
- Performance optimale quel que soit le seuil de décision

4.5.2 Interprétation de la performance exceptionnelle

L'AUC parfaite de 1.0000 peut sembler suspecte, mais elle s'explique par plusieurs facteurs convergents :

Facteurs explicatifs

1. **Séparation linéaire quasi-parfaite** : Les variables Stress.Level et Sleep.Duration créent un espace où les deux classes sont presque linéairement séparables
2. **Nature synthétique des données** : Les données simulées présentent des patterns très réguliers sans le "bruit" naturel des données cliniques réelles




FIGURE 4.2 – Courbe ROC du modèle de régression logistique (AUC = 1.0000)

3. **Taille d'échantillon de test modeste** : Avec seulement 74 observations, une seule erreur représente 1.35% et conduit tout de même à une accuracy de 98.65%
4. **Convergence des trois modèles** : Le fait que trois algorithmes différents (linéaire, ensemble, kernel) atteignent la même performance indique que la structure des données est simple et bien capturée

Implications pour l'interprétation

Cette performance exceptionnelle doit être interprétée avec prudence :

- Elle reflète probablement un **optimisme méthodologique** lié à la nature synthétique des données
- Une **validation externe** sur données cliniques réelles donnerait vraisemblablement des performances plus modestes (AUC 0.85-0.95)
- Les **relations identifiées** (hiérarchie des facteurs) restent néanmoins robustes et cohérentes avec la littérature
- Le modèle est **pédagogiquement valide** pour illustrer la méthodologie de la régression logistique

4.6 Synthèse des résultats

4.6.1 Variables significatives identifiées

Le modèle final confirme **5 prédicteurs majeurs** de la qualité du sommeil :

1. **Stress Level** - Importance 50.67 (prédicteur dominant)
2. **Sleep Duration** - Importance 38.54 (prédicteur majeur)
3. **Heart Rate** - Importance 21.42 (marqueur physiologique)

4. **Age** - Importance 6.09 (effet modéré)
5. **Daily Steps** - Importance 4.77 (activité objective)

Les trois premiers facteurs représentent à eux seuls **86.9% de l'importance prédictive totale**.

4.6.2 Performance des modèles

Performance prédictive :

- **Accuracy** : 98.65% (73/74 classifications correctes)
- **AUC** : 1.0000 (discrimination parfaite)
- **Sensibilité** : 100% (aucune bonne qualité manquée)
- **Spécificité** : 95.65% (22/23 mauvaises qualités identifiées)

Efficacité computationnelle :

- SVM RBF : 20.26 ms (le plus rapide)
- Régression Logistique : 21.11 ms (très rapide)
- Random Forest : 101.35 ms (5× plus lent)

4.6.3 Choix du modèle final

Bien que les trois modèles atteignent des performances identiques, nous recommandons la **régression logistique** pour les raisons suivantes :

1. **Interprétabilité maximale** : Coefficients et odds ratios directement interprétables
2. **Inférence statistique** : Tests de significativité disponibles
3. **Simplicité opérationnelle** : Implémentation et déploiement faciles
4. **Efficacité** : Temps d'exécution très rapide (21.11 ms)
5. **Transparence** : Compréhension intuitive pour les praticiens de santé

4.6.4 Message clé

Hierarchie des facteurs influençant le sommeil

1. **Stress Level (50.67)** - Impact dominant
2. **Sleep Duration (38.54)** - Impact majeur
3. **Heart Rate (21.42)** - Signal physiologique

Ces trois facteurs expliquent 87% de la variance prédictive

Le chapitre suivant discutera en profondeur l'interprétation de ces résultats, leurs implications pratiques et les limites méthodologiques à considérer.